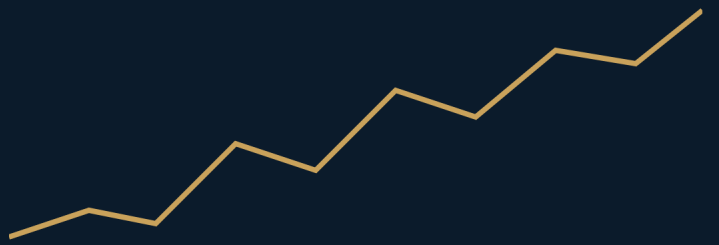
TRABAJO AGENTE · LANGCHAIN + LANGGRAPH + RAG



Market Navigator AI

Un agente que responde solo con tus documentos y se niega cuando no sabe

---

Lucas Henao · Juan David Sepúlveda · Andrés Pardo

Universidad EIA · Ingeniería de Sistemas · Semestre 7

EL PROBLEMA

Inventar es peor que no responder

Inventa

Un modelo general puede inventar definiciones financieras que suenan convincentes.

Mezcla

Mezcla conocimiento externo con el material del curso, sin decir de dónde sale.

Aconseja

Puede dar recomendaciones de inversión a estudiantes que apenas están aprendiendo.

Nuestra solución: un agente RAG que responde solo con los documentos del usuario, cita la fuente y rechaza con un texto fijo cuando no sabe.

ARQUITECTURA

Todo en la nube, salvo el modelo

Estudiante
Navegador web

→

Angular 20
Frontend en Vercel

→

FastAPI + LangGraph
Backend en Render (Docker)

↓ El backend coordina tres servicios

Supabase Auth
Valida el JWT en cada llamada

Supabase Postgres
pgvector: documentos, fragmentos e historial

Ollama, equipo local
Modelo local vía Cloudflare Tunnel. Sin API comercial de IA

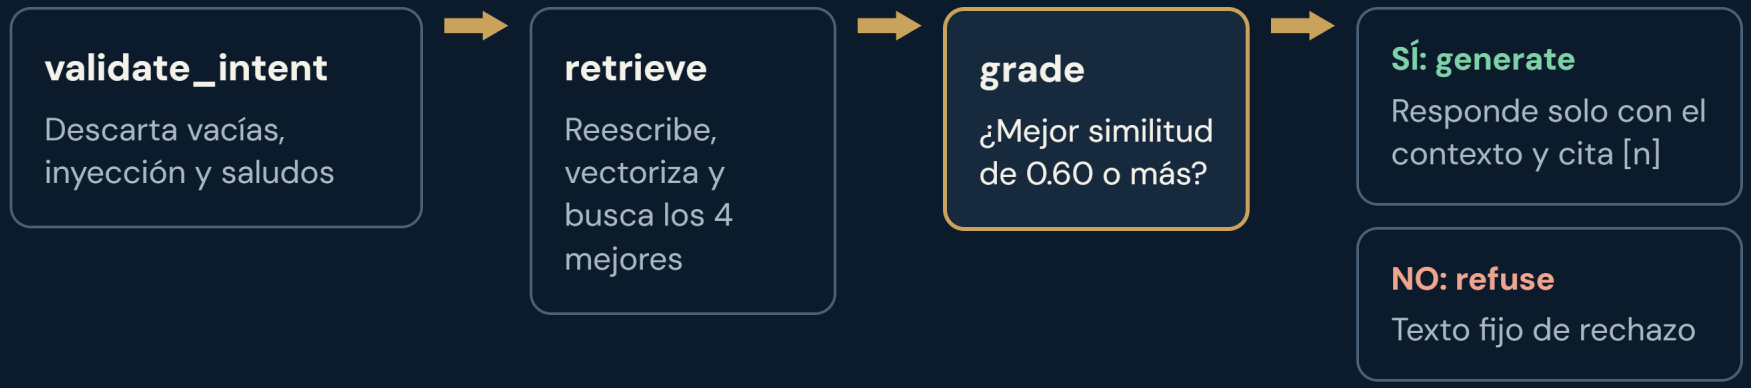
TECNOLOGÍAS

Un stack pequeño y local

Capa	Tecnología	Para qué
Frontend	Angular 20	Login, carga de documentos y chat
Backend	FastAPI, Python 3.12	API REST con autenticación JWT
Agente	LangChain + LangGraph	Grafo de estados con decisiones
Modelo local	Ollama: qwen2.5:7b	Respuestas y reescritura de consulta
Embeddings	nomic-embed-text	Vectores de 768 dimensiones
Datos	Supabase + pgvector	Documentos, fragmentos, historial
Despliegue	Docker, Render, Vercel	Nube pública y túnel de Cloudflare

AGENTE CON LANGCHAIN Y LANGGRAPH

Un grafo con dos decisiones



Ambas ramas terminan en **save_history**, que guarda el turno. Saludos y preguntas inválidas saltan directo ahí.

CONTROL DE ALUCINACIONES

Cinco controles, cero respuestas inventadas

19/20 comportamiento correcto en la evaluación

0/10 respondió lo que debía rechazar: cero alucinaciones

1/10 falso rechazo: walk-forward, similitud 0.573

Controles en capas

1. Umbral de similitud al recuperar (0.45)
2. Nodo de suficiencia (mejor fragmento, 0.60)
3. Prompt restringido al contexto
4. Rechazo con texto fijo
5. Fuentes visibles en cada respuesta

BASE VECTORIAL Y CARGA DE DOCUMENTOS

Del archivo al fragmento vectorizado

Validar
Tipo, tamaño (10 MB) y nombre

→

Extraer
PDF, DOCX, CSV, TXT y MD

→

Trocear
800 caracteres, 120 de solape

→

Vectorizar
768 dimensiones, modelo local

→

Guardar
Supabase con pgvector

→

Listo
Estado ready: ya se consulta

Búsqueda

Similitud = 1 menos la distancia coseno, filtrada por usuario: top 4 con mínimo 0.45.

Si algo falla

El documento queda como failed con el motivo; nunca medio indexado.

SEGURIDAD Y USUARIOS

Cada usuario ve solo lo suyo

Supabase Auth

Registro y login. El backend no guarda contraseñas.

JWT en cada llamada

Todo endpoint, salvo registro y login, exige token.

Aislamiento

Cada consulta filtra por usuario: nadie ve documentos ajenos.

RLS activo

Tablas cerradas a la API pública de Supabase.

Guards en Angular

Sin sesión, la pantalla del agente lleva al login.

Secretos fuera del repo

El .env se ignora; solo hay un .env.example sin valores.

Límites conocidos: el JWT vive en localStorage y el túnel de Ollama es público mientras esté abierto.

DESPLIEGUE EN LA NUBE

En producción y verificado

FRONTEND	**Vercel**	tradingsimulator-delta.vercel.app
BACKEND	**Render, Docker**	trading-simulator-papr.onrender.com
MODELO	**Ollama local**	Cloudflare Tunnel, URL temporal

Variables de entorno del backend

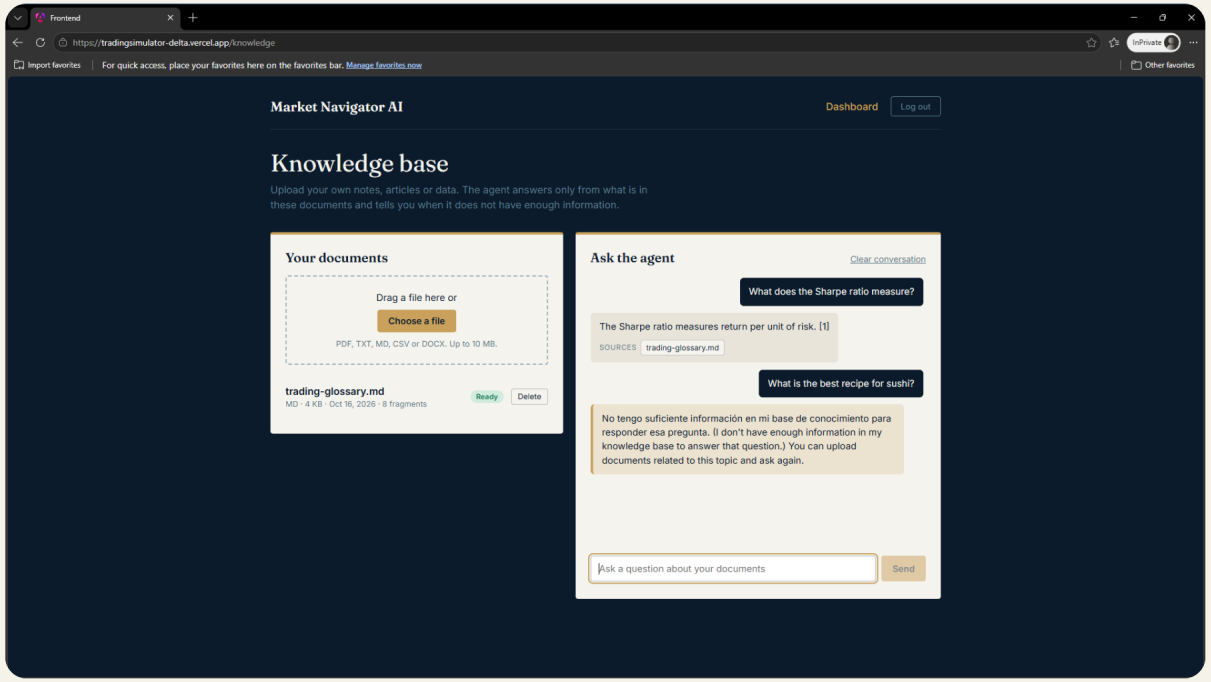
`SUPABASE_URL` `SUPABASE_KEY` `SUPABASE_SECRET_KEY` `SUPABASE_DB_URL` `OLLAMA_HOST` `CORS_ORIGINS`

Probado desde una ventana de incógnito: login, subida, respuesta con fuente y rechazo.

DEMOSTRACIÓN

En vivo, sobre la URL pública

1. Login con un usuario
2. Pregunta respondida, con fuente
3. Pregunta fuera de tema, rechazada
4. Subir un documento nuevo y preguntar por él
5. El grafo de LangGraph en el código
6. Evidencia del despliegue



CONCLUSIONES

Preferimos callar a inventar

Lo logrado

- Agente RAG desplegado, con respuestas citadas y rechazo explícito
- 19 de 20 en la evaluación, sin respuestas inventadas
- Modelo 100 % local, sin API comercial

Límites y siguiente paso

- Un umbral se solapa: trocear por encabezados corregiría el falso rechazo
- El español puntúa menos: probar embeddings multilingües
- La demo depende del equipo con Ollama encendido

¿Preguntas?